



Formando **nuevas generaciones** con **sello de excelencia** comprometidos
con la **transformación social** de las regiones y un país en paz



Modelo de un Sistema Inteligente Basado en Arquitectura de Agentes i5.0 y Modelos de Lenguaje para la Interpretación de Lengua de Señas en Entornos Digitales.

Presentado por:

Brayan David Amado Ramírez - 1092526077

Brian David Acevedo Gómez - 1092526700

Juan David Salcedo Heredia - 1096800366

Jhon Deivy Jerez Joya - 1094860952

Docente:

Sandra Maigualida Aranguren de Tarantino

Facultad de ingenierías y arquitectura

Villa del Rosario, Norte de Santander, Colombia

14 Mayo 2026



Indice

Indice	2
Resumen	4
Abstract	5
Introducción	7
Planteamiento del Problema	8
Pregunta de investigación	8
Antecedentes y Justificación	9
Antecedentes:.....	9
Justificación:.....	12
Impacto Esperado.....	14
Marco Teórico.....	15
Arquitecturas de Visión Artificial y Deep Learning	15
Inteligencia Artificial Adaptativa e Inclusiva	15
Sensores Inteligentes y Procesamiento Multidimensional.....	15
Desafíos de la Ingeniería en el Contexto Colombiano	16
Comunicación Inclusiva y Educación Mediada por IA	16
Estrategias Multimedia y Competencias Locales	16
Fundamentos de Teoría de Lenguajes y Gramáticas Formales	17
Metodología.....	18
Metodología de Ingeniería (Desarrollo del Modelo)	18
Metodología de Investigación.....	18
Objetivos	20
Objetivo General	20
Objetivos Específicos:	20
Acotaciones de la monografía	21
El alcance de este trabajo se limita a la fase de diseño y especificación técnica de alto nivel. El estudio abarca:.....	21
Alcances	21
Limitaciones	21



SC-CER96940

**"Formando nuevas generaciones con sello de excelencia comprometidos
con la transformación social de las regiones y un país en paz"**

Universidad de Pamplona
Pamplona - Norte de Santander - Colombia
Tels: (+57) 3153429495 - 3160244475
www.unipamplona.edu.co



Desarrollo	23
Objetivo Específico 1	23
1.1 Visión Computacional Aplicada al Reconocimiento de Gestos	23
1.1.1 Pipeline de Procesamiento Visual	25
1.2 Modelos de Lenguaje de Gran Escala (LLM)	26
1.2.1 Estrategia de Fine-Tuning para LSC	27
1.3 Filosofía de Agentes Inteligentes en el Marco de la Industria 5.0	28
1.3.1 Roles de Agentes Propuestos	29
1.4 Síntesis de la Base Técnica del Sistema	30
Objetivo Específico 2	31
2.1 Principios de Diseño de la Arquitectura	31
2.2 Descripción de Capas de la Arquitectura	32
2.2.1 Capa 1: Percepción y Adquisición de Datos	32
2.2.2 Capa 2: Procesamiento por Agentes Inteligentes	33
2.2.3 Capa 3: Generación de Lenguaje Natural Contextualizado	34
2.2.4 Capa 4: Presentación e Interfaz de Usuario	35
2.3 Diagrama de Flujo de Datos del Sistema	36
2.4 Integración con Plataformas Digitales	37
Objetivo Específico 3	39
3.1 Requerimientos Técnicos del Sistema	39
3.1.1 Requerimientos de Hardware	39
3.1.2 Requerimientos de Software	41
3.2 Algoritmos de Aprendizaje Profundo	42
3.2.1 Arquitectura del Codificador Temporal: Transformer Encoder	42
3.2.2 Modelo de Lenguaje: Selección y Configuración	43
3.3 Estrategias de Entrenamiento	44
3.3.1 Corpus de Entrenamiento y Gestión de Datos	44
3.3.2 Función de Pérdida y Métricas de Evaluación	45
3.3.3 Estrategia de Transferencia de Conocimiento	48
3.4 Plan de Mitigación de Riesgos Técnicos	48
Conclusiones	50
Referencias	52





Resumen

El lenguaje de señas representa el principal medio de comunicación para las personas con discapacidad auditiva; no obstante, la interacción entre personas sordas y oyentes enfrenta barreras significativas ante la escasez de herramientas que permitan una interpretación fluida en entornos digitales. El presente proyecto propone el modelado de un sistema inteligente basado en una arquitectura de agentes i5.0, diseñada para la interpretación y traducción de gestos manuales mediante el uso de visión computacional y modelos de lenguaje de gran escala (LLM).

El modelo se estructura a partir de una capa de percepción que utiliza algoritmos de visión artificial para detectar la posición y dinámica de las manos en tiempo real. Estos datos son procesados por agentes inteligentes que actúan como mediadores, traduciendo los vectores de movimiento en tokens de información. Posteriormente, estos tokens son interpretados por un modelo de lenguaje (LLM), el cual aplica técnicas avanzadas de procesamiento de lenguaje natural para estructurar frases gramaticalmente correctas y contextualizadas en español, superando las limitaciones de las traducciones literales.

Desde la perspectiva de la ingeniería básica, la propuesta define la integración lógica entre el hardware de captura y la infraestructura de procesamiento en la nube, optimizando el flujo de datos para garantizar una respuesta eficiente. El sistema se fundamenta en los pilares de la Industria 5.0, priorizando la colaboración humano-máquina y la inclusión sociotecnológica. Con este enfoque de modelado, se busca establecer las bases técnicas para una herramienta que funcione



como un intermediario tecnológico robusto, escalable y accesible, orientada a mejorar la comunicación inclusiva en la sociedad digital.

Palabras clave: Agentes i5.0, Modelos de Lenguaje (LLM), Visión Computacional, Modelado Continuo, Ingeniería Básica.

Abstract

Sign language is the primary means of communication for people with hearing disabilities; however, the interaction between deaf and hearing individuals faces significant barriers due to the scarcity of tools that allow fluid interpretation in digital environments. This project proposes the modeling of an intelligent system based on an i5.0 agent architecture, designed for the interpretation and translation of manual gestures using computer vision and Large Language Models (LLM).

The model is structured around a perception layer that utilizes computer vision algorithms to detect the position and dynamics of the hands in real-time. This data is processed by intelligent agents acting as mediators, translating motion vectors into information tokens. Subsequently, these tokens are interpreted by a Large Language Model (LLM), which applies advanced natural language processing techniques to structure grammatically correct and contextualized sentences in Spanish, overcoming the limitations of literal translations.

From a basic engineering perspective, the proposal defines the logical integration between capture hardware and cloud processing infrastructure, optimizing data flow to ensure an efficient response. The system is based on the pillars of Industry 5.0, prioritizing human-machine collaboration and socio-technological inclusion. With this modeling approach, the aim is to



establish the technical foundations for a tool that serves as a robust, scalable, and accessible technological intermediary, aimed at improving inclusive communication in the digital society.

Keywords: i5.0 Agents, Large Language Models (LLM), Computer Vision, Continuous Modeling, Basic Engineering.



Introducción

El presente documento constituye el cuerpo técnico del proyecto de investigación titulado Modelo de un Sistema Inteligente Basado en Arquitectura de Agentes i5.0 y Modelos de Lenguaje para la Interpretación de Lengua de Señas en Entornos Digitales, adscrito al semillero de investigación SIDDFAI de la Universidad de Pamplona. El desarrollo que se expone a continuación corresponde a los tres primeros objetivos específicos del proyecto, los cuales conforman la fase de fundamentación científica y diseño de la arquitectura del sistema inteligente propuesto.

La aplicación de la discapacidad auditiva en la interacción humana plantea un desafío importante en el campo de la ingeniería inclusiva y la Industria 5.0. Alsaleh [2] afirma que el uso de la inteligencia artificial (IA) en entornos accesibles ha mostrado grandes avances para la autonomía de las personas con discapacidad. Esto ha abierto un nuevo área de investigación que combina varios campos, incluyendo la visión por computadora, el procesamiento del lenguaje natural y los sistemas multiagente.

La estructura del presente informe sigue los lineamientos metodológicos establecidos en la propuesta, abordando en primera instancia el análisis de los fundamentos teóricos del sistema, seguido del diseño de su arquitectura lógica y funcional, y finalizando con la especificación técnica de los algoritmos de aprendizaje profundo y estrategias de entrenamiento que soportarán el modelo de reconocimiento de señas.



Planteamiento del Problema

Las personas con discapacidad auditiva enfrentan múltiples dificultades para comunicarse con personas oyentes en diferentes contextos como instituciones educativas, entornos laborales o servicios públicos. Aunque el lenguaje de señas permite una comunicación efectiva dentro de la comunidad sorda, la mayoría de la población no posee conocimientos sobre este lenguaje, lo cual genera barreras significativas de interacción.

En los últimos años se han desarrollado avances en inteligencia artificial y visión computacional que permiten analizar imágenes y reconocer patrones visuales complejos, incluyendo gestos humanos. Sin embargo, muchas de estas soluciones requieren hardware especializado o no están disponibles en aplicaciones accesibles para el público en general. Además, la mayoría de los sistemas actuales se limitan a traducciones literales, dejando de lado el contexto y la gramática natural del lenguaje.

Por esta razón, nace la necesidad de modelar un sistema inteligente basado en una arquitectura de agentes y modelos de lenguaje que permitan interpretar gestos de manera fluida. El objetivo es procesar la información visual y transformarla en lenguaje comprensible y contextualizado para usuarios oyentes, mediante herramientas que sean técnicamente viables y accesibles dentro de los estándares de la Industria 5.0.

Pregunta de investigación

¿Cómo modelar un sistema inteligente basado en agentes i5.0, visión computacional y modelos de lenguaje que permita la interpretación y traducción de lengua de señas en entornos digitales?



Antecedentes y Justificación

Antecedentes:

Internacional [Prompt de Búsqueda: "Sign Language" AND "Artificial Intelligence" AND "2025"]

- Yerimbetova et al. (2026): En su estudio "Sign Language Recognition based on Deep Learning via MediaPipe", proponen una arquitectura que combina el extractor de puntos clave MediaPipe con decodificadores tipo Transformer para convertir video en texto. Este antecedente es fundamental para nuestro proyecto, ya que valida la elección de MediaPipe como herramienta base para el modelado. Mientras Yerimbetova se enfoca en el lenguaje de señas de Kazajistán, nuestro modelo adapta esa misma robustez técnica para la Lengua de Señas Colombiana (LSC), integrando además agentes i5.0 para mejorar la interpretación del contexto. [22]
- Alsaleh (2026): En la investigación titulada "The influence of artificial intelligence on individuals with disabilities", se analiza cómo la IA personalizada y el procesamiento de lenguaje natural (NLP) aumentan la autonomía de personas con discapacidad. El trabajo de Alsaleh sustenta el pilar de "Bienestar Humano" de nuestra propuesta bajo el marco de la Industria 5.0. Cruzamos su hallazgo sobre la necesidad de "personalización en tiempo real" con nuestro diseño de agentes inteligentes, asegurando que el sistema no solo traduzca, sino que se adapte a las necesidades del usuario. [23]
- Jin et al. (2026): En su artículo sobre sensores flexibles y avances en IA, discuten el monitoreo continuo y la precisión en la captura de datos multidimensionales para el movimiento humano. Aunque Jin se enfoca en hardware (sensores), su análisis sobre la importancia de la baja latencia en la respuesta de la IA se cruza directamente con nuestro



requerimiento de procesamiento en tiempo real. Esto justifica por qué nuestro modelado prioriza arquitecturas de agentes ligeras que permitan una comunicación fluida sin retrasos técnicos. [24]

Nacional [Prompt de Búsqueda: "Lengua de señas colombiana" AND "Inteligencia Artificial" AND "2025"]

- Revista Facultad de Ingeniería (2025): En el artículo sobre tendencias de ingeniería en Colombia publicado en Scielo, se habla de cómo el país está adoptando tecnologías disruptivas para cerrar brechas sociales. Esto me sirve para justificar que mi proyecto no es solo un capricho técnico, sino que va alineado con lo que la academia en Colombia está pidiendo: usar la ingeniería para resolver problemas reales de nuestra gente, como la comunicación de la comunidad sorda. [25]
- UniBoyacá (2025): En este repositorio encontré trabajos sobre el uso de herramientas digitales para la inclusión. Explican cómo crear interfaces que de verdad sean fáciles de usar para personas con discapacidad. Tomo esta idea para mi diseño. No quiero que mi sistema sea solo código, sino que la interfaz sea amigable y pensada para el usuario, conectando el modelado técnico con la experiencia humana que proponen estas universidades. [26]
- UNAD (2024-2025): Revisando el repositorio de la UNAD, hay proyectos que exploran cómo la inteligencia artificial y el software libre pueden ayudar en la educación y la comunicación inclusiva en regiones apartadas. Esto refuerza mi idea de hacer un modelo basado en la web. Al igual que lo que plantean en la UNAD, busco que la solución sea



accesible y que pueda funcionar en diferentes contextos, aprovechando que hoy en día casi cualquier computador tiene una cámara. [27]

Regional [Prompt de Búsqueda: "Norte de Santander" "discapacidad auditiva" "tecnología"]

- Pérez León (2021) / Instituto Técnico Guaimaral: En su investigación sobre discapacidad auditiva y pedagogías emergentes en Cúcuta, el autor analiza cómo la transición a modelos tecnológicos dejó ver los grandes retos que tienen los estudiantes sordos para comunicarse y aprender en entornos digitales. Este estudio me sirve para demostrar que en Cúcuta existe una necesidad real de herramientas mediadas por tecnología. Mientras Pérez León se enfoca en el desafío pedagógico, mi proyecto propone la solución técnica mediante el modelado de un sistema de interpretación, cerrando esa brecha digital que él identifica en los colegios de la ciudad. [28]
- Jiménez & Serrano (2022) / SENA Regional Norte de Santander: En su trabajo para la Universidad Simón Bolívar, desarrollaron una estrategia multimedia para integrar las TIC en estudiantes con problemas auditivos del SENA en Cúcuta, buscando facilitar su acceso a una educación de calidad. Conecto este antecedente con mi propuesta de Industria 5.0. Ellos demuestran que las herramientas multimedia son vitales para la inclusión laboral y educativa en la región. Mi modelo de agentes inteligentes lleva esa idea un paso más allá, permitiendo que la comunicación no sea solo a través de contenidos fijos, sino mediante una interpretación dinámica en tiempo real. [29]
- Vargas & Peñuela (2022) / Colegio Guaimaral: Esta investigación se centró en crear estrategias didácticas usando la Lengua de Señas Colombiana (LSC) para mejorar el aprendizaje en niños con déficit auditivo en Cúcuta. Este trabajo es clave porque se enfoca



específicamente en la LSC y en la importancia de material que sea visual y tangible. Mi modelo toma esa importancia de la lengua de señas local para asegurar que el sistema inteligente respete los modismos y la estructura que se usa aquí en la región, y no una lengua de señas genérica. [30]

Justificación:

Este proyecto nace de la necesidad de usar la ingeniería no solo para automatizar, sino para resolver problemas humanos reales. A continuación, se detallan los impactos que busca generar este modelo:

- **Impacto Tecnológico (El salto a la Industria 5.0):** Nuestra propuesta no se queda solo en la Industria 4.0, que se trataba de conectar máquinas y datos. Aquí nos movemos hacia la Industria 5.0, donde el enfoque es el bienestar humano. Al integrar agentes inteligentes y modelos de lenguaje (LLM), el sistema deja de ser un software frío y se convierte en una herramienta capaz de entender el contexto de la persona sorda, adaptándose a ella de forma personalizada.
- **Impacto Social (Inclusión Real):** Este es el corazón del proyecto. En Cúcuta, como vimos en los antecedentes del Colegio Guaimaral, hay una barrera gigante para las personas sordas. Con este sistema, buscamos darles autonomía. No tendrán que depender siempre de un intérprete físico para trámites o clases; el modelo les da una voz digital en tiempo real, eliminando esa exclusión que han vivido por años.
- **Impacto Económico (Productividad Inclusiva):** Desarrollar este modelo es mucho más eficiente que los costos actuales. Para las instituciones públicas en Norte de Santander, reduciría el gasto de tener traductores permanentes en cada ventanilla. Además, ayuda a





que más personas con discapacidad auditiva entren al mercado laboral, porque con una herramienta de traducción a la mano, pueden ser más productivas y competitivas.

- **Impacto Ambiental (Sostenibilidad Digital):** Aunque sea software, también ayudamos al planeta. Al ser una herramienta web, promovemos la desmaterialización: menos papeles, menos guías impresas y, sobre todo, menos necesidad de que la gente se desplace físicamente solo para buscar a alguien que les traduzca. Todo es digital, rápido y con una huella de carbono mucho menor.



Impacto Esperado

El desarrollo de este modelado busca generar resultados tangibles en las siguientes dimensiones:

- **Impacto Social:** Se espera reducir las barreras de comunicación en entornos cotidianos de la región, proporcionando una herramienta que otorgue autonomía a la persona sorda. El impacto real es transformar la tecnología en un puente de inclusión que facilite la interacción sin necesidad de un intérprete humano constante, promoviendo la igualdad de oportunidades en servicios públicos y educativos.
- **Impacto Tecnológico:** El proyecto busca validar la eficiencia de arquitecturas basadas en agentes inteligentes y modelos de lenguaje (LLM) aplicados a la visión artificial. Se espera demostrar que es posible procesar la Lengua de Señas Colombiana (LSC) con baja latencia y alta precisión, estableciendo un referente técnico para futuros desarrollos de software inclusivo en la universidad.
- **Impacto Académico:** Este trabajo pretende fortalecer la línea de investigación en Sistemas Inteligentes de la Universidad de Pamplona. Se espera que el modelado sirva como base de conocimiento para otros estudiantes, incentivando el uso de frameworks avanzados (como MediaPipe y Transformers) y demostrando que la ingeniería de sistemas es el motor principal para resolver problemáticas sociales complejas mediante la innovación.



Marco Teórico

El presente modelado se fundamenta en la integración de tecnologías de vanguardia y realidades sociales locales, estructurándose bajo los siguientes pilares técnicos y científicos:

Arquitecturas de Visión Artificial y Deep Learning

Para que el sistema reconozca la lengua de señas, la base técnica actual es el uso de redes neuronales profundas. Según el marco metodológico de Yerimbetova et al. [22], el uso del framework MediaPipe permite extraer 225 puntos clave (keypoints) en 3D de cada frame de video. Estos datos alimentan un codificador de Redes de Convolución Temporal (TCN) y un decodificador tipo Transformer, lo que garantiza que el sistema no solo vea una imagen, sino que entienda el movimiento en el tiempo para convertirlo en texto con alta precisión [22].

Inteligencia Artificial Adaptativa e Inclusiva

La IA ha pasado de ser una herramienta de automatización a un motor de independencia. Como analiza Alsaleh [23], la tendencia global de 2025-2026 es el uso de Procesamiento de Lenguaje Natural (NLP) y personalización en tiempo real para eliminar barreras cognitivas y de comunicación. Este enfoque permite que el sistema se adapte a las variaciones individuales de los usuarios con discapacidad, mejorando significativamente su calidad de vida y autonomía [23].

Sensores Inteligentes y Procesamiento Multidimensional

Aunque el modelo se basa en cámaras, la teoría de captura de movimiento se apoya en el análisis multidimensional. Investigaciones sobre sensores flexibles de Jin et al. [24] destacan que la captura continua de datos debe ser capaz de filtrar artefactos de movimiento y ruido. Esto



justifica que el modelado del software deba priorizar algoritmos de IA robustos que manejen grandes volúmenes de datos biométricos para asegurar una respuesta inmediata y precisa [24].

Desafíos de la Ingeniería en el Contexto Colombiano

A nivel nacional, la ingeniería se enfrenta al reto de cerrar brechas sociales mediante la transformación digital. De acuerdo con la Revista Facultad de Ingeniería [25], el contexto colombiano exige soluciones disruptivas que se adapten a la infraestructura local. Esto implica que el desarrollo de herramientas digitales debe estar alineado con las políticas de inclusión social del país, buscando que la tecnología sea accesible y funcional en entornos reales de Colombia [26].

Comunicación Inclusiva y Educación Mediada por IA

La aplicación de la IA en la comunicación no es solo técnica, sino pedagógica. Según estudios de la UNAD [27], las plataformas inteligentes deben diseñarse bajo criterios de accesibilidad universal. Esto se conecta con los hallazgos de Pérez León [28] en Cúcuta, quien advierte que la transición a lo digital en colegios como el Guaimaral requiere modelos de enseñanza que no dejen atrás a la población sorda, planteando un desafío directo para que el software de traducción sea una herramienta de apoyo en el aula [28].

Estrategias Multimedia y Competencias Locales

Finalmente, el éxito de un sistema de traducción depende de entender la Lengua de Señas Colombiana (LSC). En Norte de Santander, el trabajo del SENA [29] demuestra que las estrategias multimedia facilitan la integración de las TIC en la formación profesional. Asimismo, investigaciones de la UFPS [29] realizadas en el Colegio Guaimaral confirman que el uso de



materiales visuales y tecnológicos es clave para que los estudiantes con déficit auditivo desarrollen competencias complejas, validando así la necesidad de nuestro modelado de agentes inteligentes [29].

Fundamentos de Teoría de Lenguajes y Gramáticas Formales

Para que el modelado sea funcional, debemos tratar la Lengua de Señas Colombiana (LSC) como un Lenguaje Formal. Según la jerarquía de Chomsky, el sistema debe ser capaz de procesar cadenas de símbolos (gestos) y convertirlas en estructuras gramaticales coherentes.

Alfabeto y Vocabulario (Σ): En nuestro modelo, el alfabeto no son letras, sino los queremas (unidades mínimas de la seña como configuración y movimiento). El sistema define un conjunto finito de símbolos que representan cada gesto capturado por MediaPipe [22][28].

Gramática de Contexto Libre: La LSC tiene una estructura donde el orden de las señas define el sentido. Utilizaremos el procesamiento de los LLM [22] para actuar como un Analizador Sintáctico (Parser). Este "parser" toma los gestos identificados y los organiza según las reglas de producción del español, asegurando que la salida de texto no sea una simple lista de palabras, sino una oración con coherencia gramatical.

Uso en el Proyecto: Aplicaremos autómatas de estado finito para determinar el inicio y fin de una seña (segmentación). Esto evita que el sistema intente traducir movimientos naturales que no forman parte de una palabra, permitiendo que el agente inteligente solo procese cadenas válidas dentro del diccionario de la LSC [27][29].



Metodología

Para el cumplimiento de los objetivos, el proyecto se estructura bajo dos enfoques metodológicos complementarios:

Metodología de Ingeniería (Desarrollo del Modelo)

Se utilizará una adaptación de la Metodología de Ciclo de Vida en Cascada (Waterfall) enfocada al diseño de ingeniería. Al ser un proyecto de modelado, se requiere un avance secuencial y documentado en las siguientes fases:

1. Análisis de Requerimientos: Definición de las necesidades técnicas para la captura de video y los parámetros de los modelos de lenguaje (LLM).
2. Diseño de la Arquitectura: Modelado de la interacción entre los agentes i5.0 y los algoritmos de visión computacional.
3. Especificación Técnica: Selección de las herramientas de IA, definición de los flujos de datos y diseño de la interfaz lógica del sistema.
4. Validación del Modelo: Evaluación teórica de la viabilidad del sistema y documentación técnica final.

Metodología de Investigación

El proyecto se desarrolla bajo un enfoque cualitativo y de carácter descriptivo. La investigación se divide en las siguientes fases:



- Fase Documental: Recolección y análisis de información científica sobre Redes Neuronales, Visión Artificial y procesamiento de lenguaje natural en bases de datos académicas.
- Fase Analítica: Comparación de las diferentes tecnologías de IA actuales para determinar cuál se adapta mejor a los pilares de la Industria 5.0.
- Fase de Síntesis (Propuesta Final): Integración de los conocimientos obtenidos para proponer el modelo final que solucione la brecha de comunicación de la comunidad sorda.



SC-CER96940

"Formando nuevas generaciones con sello de excelencia comprometidos con la transformación social de las regiones y un país en paz"

Universidad de Pamplona
Pamplona - Norte de Santander - Colombia
Tels: (+57) 3153429495 - 3160244475
www.unipamplona.edu.co



Objetivos

Objetivo General

Modelar un sistema inteligente basado en una arquitectura de agentes i5.0 que integre visión computacional y modelos de lenguaje de gran escala (LLM), orientado a la interpretación y traducción de lengua de señas en tiempo real dentro de entornos digitales, mediante el diseño de su ingeniería básica y funcional.

Objetivos Específicos:

1. Analizar los fundamentos teóricos de la visión computacional, los modelos de lenguaje (LLM) y la filosofía de agentes i5.0 para establecer la base técnica del sistema.
2. Estructurar la arquitectura lógica y funcional que permita la captura de video, el procesamiento de agentes y la generación de texto contextualizado mediante modelos de lenguaje
3. Especificar los requerimientos técnicos, algoritmos de aprendizaje profundo y estrategias de entrenamiento necesarios para la puesta en marcha del modelo de reconocimiento de señas.
4. Estructurar el protocolo de comunicación y flujo de datos entre los agentes i5.0 y los modelos de lenguaje para asegurar una traducción coherente y fluida en plataformas web.
5. Determinar los criterios de validación y métricas de rendimiento para proyectar la viabilidad del modelo en un entorno de uso real (caso de estudio), minimizando los riesgos de implementación.



Acotaciones de la monografía

El alcance de este trabajo se limita a la fase de diseño y especificación técnica de alto nivel. El estudio abarca:

Alcances

- La construcción de un marco conceptual sobre la arquitectura de agentes i5.0 aplicable al lenguaje.
- La definición del pipeline de procesamiento de visión computacional mediante el uso de librerías de extracción de landmarks.
- La estrategia de refinamiento (fine-tuning) para adaptar modelos de lenguaje a la sintaxis y pragmática de la LSC.
- La modelación lógica de la interacción entre agentes (percepción, traducción y generación de respuesta).

Limitaciones

- Ausencia de Prototipado en Código: Dado que el trabajo se circunscribe a la parte escrita, no se realizarán pruebas de laboratorio, entrenamiento de modelos o despliegue de software, por lo que los resultados de desempeño son estimaciones basadas en la arquitectura propuesta.
- Calidad de Datos Visuales: La efectividad del sistema descrito depende de condiciones externas al diseño del proyecto, tales como la calidad de iluminación y el hardware de captura (cámaras) del usuario final.
- Variabilidad Lingüística: La LSC posee variaciones regionales y dialectales que, aunque se consideran en el diseño, no pueden ser totalmente cubiertas sin una base de datos amplia, factor que se reconoce como una limitación inherente a la fase de diseño.





- Conectividad: El modelo asume una latencia de red estándar; fluctuaciones severas en el ancho de banda no son abordadas dentro de los protocolos de comunicación de la arquitectura propuesta.



Desarrollo

Objetivo Específico 1

Analizar los fundamentos teóricos de la visión computacional, los modelos de lenguaje (LLM) y la filosofía de agentes i5.0 para establecer la base técnica del sistema.

1.1 Visión Computacional Aplicada al Reconocimiento de Gestos

La visión computacional (VC) es una rama de la inteligencia artificial que dota a los sistemas de cómputo de la capacidad de interpretar y procesar información proveniente del mundo visual. En el contexto del reconocimiento de lengua de señas, la visión computacional actúa como la capa perceptual primaria del sistema, siendo responsable de la adquisición, preprocesamiento y representación estructurada de los gestos manuales capturados a través de dispositivos de video estándar.

El proceso técnico de reconocimiento de gestos comienza con la captura de secuencias de video en tiempo real, a partir de las cuales se extraen fotogramas individuales que son procesados de manera secuencial. Cada fotograma es sometido a una serie de transformaciones matemáticas y estadísticas orientadas a la detección de regiones de interés, específicamente las extremidades superiores del usuario. Para ello, se emplean arquitecturas de detección basadas en aprendizaje profundo, entre las que se destaca el framework MediaPipe Holistic, desarrollado por Google y ampliamente validado en la literatura científica reciente.




Ilustración 1 . Ejemplo Aplicativo Del Software

Según Yerimbetova [1], el framework MediaPipe permite la extracción de hasta 225 puntos clave (keypoints) tridimensionales por cada fotograma de video procesado. Estos puntos clave se distribuyen estratégicamente sobre las articulaciones de los dedos, la palma de la mano, la muñeca y los nodos del antebrazo, generando una representación vectorial densa del gesto en un espacio de tres dimensiones (X, Y, Z). La tercera dimensión de profundidad, aunque estimada de manera relativa desde una cámara RGB convencional, proporciona información crucial sobre la orientación y la curvatura de la mano durante la ejecución de una señal.

Desde una perspectiva matemática, cada fotograma produce una matriz de características de dimensión $M \times N \times 3$, donde M representa el número de puntos clave activos, N el número de componentes vectoriales espaciales y 3 los canales de coordenadas tridimensionales (X, Y, Z). Esta representación tensorial es posteriormente normalizada respecto al centroide de la muñeca para garantizar la invarianza ante traslaciones y cambios de escala, haciendo que el sistema sea robusto frente a variaciones en la posición del usuario respecto a la cámara

Según Jin [3], la colección continua y multifacética de información biométrica requiere mecanismos de filtrado que eliminen el movimiento y el ruido aleatorio. Dentro de esta



propuesta, estos artefactos se entienden como micro movimientos involuntarios de las manos, cambios en el entorno de luz y dedos parcialmente obstruidos durante la realización de signos complejos. Para abordar estos problemas, el modelo integra un filtro de media móvil ponderada exponencialmente (EWMA) respecto al eje del tiempo de los puntos clave. Este arreglo garantiza una señal de entrada suave y consistente para las siguientes etapas del modelo.

1.1.1 Pipeline de Procesamiento Visual

El pipeline de procesamiento visual propuesto comprende las siguientes etapas secuenciales: (a) Adquisición de video mediante cámara RGB a una resolución mínima de 720p y una tasa de fotogramas de 30 FPS; (b) Detección y segmentación de la región de la mano mediante el modelo BlazePalm de MediaPipe, que opera sobre el fotograma completo a escala reducida para localizar las regiones de interés con bajo costo computacional [1]; (c) Estimación de pose y extracción de keypoints mediante el modelo Hand Landmark del mismo framework, que actúa sobre la región segmentada con alta resolución y precisión subpixel; (d) Normalización y construcción del vector de características en espacio tridimensional; y (e) Agrupación temporal de keypoints en ventanas deslizantes de T fotogramas, configurando secuencias aptas para su ingesta en los modelos de aprendizaje profundo.




Ilustración 2 Modelo de Aplicación Del Procesamiento Pipeline

Este pipeline ha demostrado latencias de inferencia menores a 12 milisegundos por fotograma en hardware de gama media, lo que es consistente con los requisitos de tiempo real establecidos en la propuesta. Adicionalmente, el diseño modular del pipeline facilita la integración con las capas de agentes inteligentes definidas en los objetivos posteriores, respetando la separación de responsabilidades que caracteriza a las arquitecturas de sistemas distribuidos.

1.2 Modelos de Lenguaje de Gran Escala (LLM)

Los Modelos de Lenguaje de Gran Escala, conocidos por sus siglas en inglés como Large Language Models (LLM), representan el estado del arte en el procesamiento de lenguaje natural (NLP). Su arquitectura fundamental se basa en el mecanismo de atención multi-cabeza (Multi-Head Attention) propuesto por Vaswani (2017), que permite al modelo ponderar contextualmente las relaciones semánticas entre tokens de una secuencia de manera paralela y eficiente, superando ampliamente las limitaciones de los modelos recurrentes (LSTM, GRU) en el manejo de dependencias de largo alcance.

En el contexto del presente sistema, los LLM cumplen un doble rol funcional. En primera instancia, actúan como decodificadores semánticos de las representaciones vectoriales generadas



por la capa de visión computacional, mapeando secuencias de vectores de keypoints a tokens de texto en español. En segunda instancia, actúan como generadores de lenguaje natural contextualizado, produciendo oraciones gramaticalmente correctas y semánticamente coherentes que van más allá de la simple concatenación de palabras aisladas, tal como lo señala Alsaleh [2] en su análisis sobre personalización en tiempo real para personas con discapacidad.

Técnicamente, el pipeline LLM propuesto opera bajo una arquitectura del tipo encoder-decoder. El encoder recibe como entrada la secuencia de vectores de keypoints normalizados, producida por la capa de visión computacional, y genera una representación de alta dimensionalidad en un espacio latente compartido. El decoder, por su parte, autoregresivamente genera los tokens de salida en español, condicionado tanto a la representación latente del encoder como a los tokens generados anteriormente en la secuencia. Este diseño garantiza que la traducción final incorpore el contexto gramatical y el flujo temporal de la seña, y no solo su representación instantánea.

1.2.1 Estrategia de Fine-Tuning para LSC

La Lengua de Señas Colombiana (LSC) presenta particularidades morfosintácticas que la distinguen significativamente del español hablado, así como de otras lenguas de señas como la ASL (American Sign Language) o la LSE (Lengua de Señas Española). En la LSC, el orden canónico de los constituyentes es Sujeto-Objeto-Verbo (SOV), contrario al Sujeto-Verbo-Objeto (SVO) del español. Adicionalmente, la LSC hace uso extensivo de clasificadores espaciales y de mecanismos de topicalización que no tienen equivalente directo en el lenguaje verbal escrito.

Para adaptar un LLM preentrenado (como GPT o LLaMA) a la especificidad lingüística de la LSC, se propone una estrategia de fine-tuning supervisado sobre un corpus bilingüe seña-



español compuesto por pares de secuencias de keypoints y sus transcripciones en español. Este proceso ajusta los pesos del modelo base mediante el minimizador de la función de pérdida de entropía cruzada categórica sobre el vocabulario objetivo, permitiendo que el sistema aprenda la correspondencia entre las representaciones gestuales de la LSC y las estructuras gramaticales del español. Los antecedentes de Vargas & Peñuela [9] en el Colegio Guaimaral de Cúcuta validan la importancia de preservar las particularidades de la LSC regional en cualquier herramienta de apoyo comunicativo.




Ilustración 3 Método De Aplicación FineTuning Para Traducción De Lenguaje Maquina a Lenguaje Normal

1.3 Filosofía de Agentes Inteligentes en el Marco de la Industria 5.0

La Industria 5.0 (i5.0) representa la evolución del paradigma industrial más allá de la automatización masiva propuesta por la Industria 4.0, reintroduciendo al ser humano como actor central en los ecosistemas productivos y tecnológicos. Sus tres pilares fundamentales son:

- (a) Centralidad humana: la tecnología debe servir al bienestar de las personas y no al contrario;
- (b) Sostenibilidad: los sistemas deben diseñarse con criterios de eficiencia energética y mínimo impacto ambiental;
- y (c) Resiliencia: las arquitecturas deben ser adaptables, tolerantes a fallos y capaces de operar en condiciones variables.



En el campo de la inteligencia artificial aplicada, estos principios se materializan en la arquitectura de agentes inteligentes, entendidos como entidades computacionales autónomas que perciben su entorno, razonan sobre él y ejecutan acciones orientadas a objetivos específicos. Un sistema multi-agente (MAS, del inglés Multi-Agent System) integra múltiples agentes con roles diferenciados que colaboran, compiten o negocian entre sí para resolver problemas complejos que superan las capacidades de un agente individual.

La relevancia de los agentes i5.0 en el presente proyecto reside en su capacidad para descomponer el problema complejo del reconocimiento y traducción de la lengua de señas en subtarear especializadas manejables de forma distribuida. Según el análisis de la Revista Facultad de Ingeniería [4], el contexto colombiano exige soluciones disruptivas y escalables, condición que la arquitectura multi-agente satisface de manera natural al permitir la incorporación de nuevos agentes funcionales sin alterar el núcleo del sistema existente. Esta modularidad es fundamental para la viabilidad del proyecto en entornos de infraestructura variable como los prevalentes en Norte de Santander.

1.3.1 Roles de Agentes Propuestos

La arquitectura de agentes propuesta define los siguientes roles funcionales: (1) Agente Perceptor: responsable de la adquisición y preprocesamiento de los fotogramas de video, extrayendo los vectores de keypoints mediante MediaPipe y realizando el filtrado de ruido [1]; (2) Agente Codificador: encargado de transformar las secuencias de keypoints en representaciones de alta dimensionalidad compatibles con el encoder del LLM, aplicando técnicas de embedding temporal y normalización de secuencias; (3) Agente Traductor: gestiona la invocación del LLM y la generación autoregressiva del texto en español, manejando la caché de contexto conversacional



para asegurar coherencia entre traducciones consecutivas [2]; y (4) Agente de Presentación: responsable de la renderización del texto generado en la interfaz de usuario web, aplicando criterios de accesibilidad visual y ajuste tipográfico.

Esta distribución de responsabilidades respeta el principio de separación de incumbencias de la ingeniería de software, garantizando que cada agente sea testeable, reemplazable y escalable de manera independiente. La comunicación entre agentes se realiza mediante colas de mensajes asíncronas, patrón que permite absorber picos de carga sin generar cuellos de botella en el pipeline de procesamiento y que es consistente con los estándares de arquitecturas orientadas a eventos ampliamente adoptados en sistemas distribuidos modernos.

1.4 Síntesis de la Base Técnica del Sistema

La convergencia de los tres pilares teóricos analizados visión computacional con MediaPipe, modelos de lenguaje de gran escala y filosofía de agentes i5.0 configura lo que es una base técnica sólida y coherente para el sistema propuesto. La integración de estas tecnologías no es arbitraria: responde a una cadena funcional en la que cada componente alimenta al siguiente, desde la percepción visual hasta la generación de lenguaje natural, pasando por la mediación semántica de los agentes inteligentes.

Los antecedentes nacionales revisados por la UNAD [6] y la Universidad de Boyacá [5] confirman la pertinencia de desarrollar herramientas de comunicación inclusiva basadas en IA en el contexto colombiano, alineando el presente proyecto con las tendencias académicas y las necesidades sociales del país.



Objetivo Específico 2

Estructurar la arquitectura lógica y funcional que permita la captura de video, el procesamiento de agentes y la generación de texto contextualizado mediante modelos de lenguaje.

2.1 Principios de Diseño de la Arquitectura

El diseño de la arquitectura lógica y funcional del sistema inteligente se fundamenta en tres principios de ingeniería de software que garantizan su viabilidad técnica, escalabilidad operativa y alineación con los principios de la Industria 5.0: (a) Modularidad: cada componente del sistema es una unidad funcional autocontenida con interfaces bien definidas, lo que facilita el mantenimiento, la sustitución tecnológica y la incorporación futura de mejoras sin impactar el funcionamiento global; (b) Bajo Acoplamiento y Alta Cohesión: los módulos son interdependientes solo a través de contratos de comunicación formales (APIs, colas de mensajes), minimizando las dependencias directas que incrementan la complejidad y la fragilidad del sistema; y (c) Orientación a Eventos: la arquitectura adopta un paradigma asíncrono basado en eventos para el flujo de datos, garantizando que el sistema sea responsive y tolerante a variaciones en la latencia de procesamiento de los diferentes agentes.

Estos principios son consistentes con los requerimientos de sistemas de traducción en tiempo real descritos por Yerimbetova [1], quienes enfatizan que la baja latencia y la robustez ante interrupciones son condiciones sine qua non para que un sistema de reconocimiento de lengua de señas sea utilizable en contextos cotidianos. Adicionalmente, la orientación a eventos facilita la integración futura con plataformas de comunicación existentes como videoconferencias o asistentes virtuales, amplificando el impacto social del sistema.



2.2 Descripción de Capas de la Arquitectura

2.2.1 Capa 1: Percepción y Adquisición de Datos

La primera capa de la arquitectura es responsable de la interacción directa con el entorno físico del usuario. Su función principal es la adquisición de video en tiempo real mediante la cámara del dispositivo del usuario (computador portátil, tablet o smartphone), el preprocesamiento de los fotogramas y la extracción de los vectores de keypoints.

Técnicamente, esta capa se implementa como un módulo JavaScript/TypeScript ejecutado en el navegador del usuario, aprovechando la API MediaPipe Tasks Vision disponible para entornos web. La ejecución en el lado del cliente tiene implicaciones técnicas relevantes: en primer lugar, elimina la necesidad de transmitir flujos de video hacia servidores remotos, reduciendo drásticamente el consumo de ancho de banda y los riesgos de privacidad asociados al procesamiento de datos biométricos en la nube [3]. En segundo lugar, aprovecha las capacidades de aceleración por hardware del dispositivo del usuario (GPU integrada, NPU) mediante las APIs WebGL y WebAssembly.




Ilustración 4 Lenguajes Usados Para la Implementación Modular

El flujo de procesamiento dentro de esta capa opera de la siguiente manera: el bucle de captura de video solicita un fotograma al stream de la cámara a una frecuencia de 30 Hz; el fotograma es procesado por el modelo BlazePalm para la detección de la región de la mano; sobre



la región detectada se ejecuta el modelo Hand Landmark para la extracción de los 21 puntos clave por mano (42 en total para ambas manos, más 33 puntos de pose corporal y 478 puntos faciales, sumando los 225 puntos clave relevantes documentados por Yerimbetova et al. [1].

Yerimbetova [1] documentan que esta configuración de extracción produce vectores de keypoints que, cuando son normalizados respecto a las dimensiones del fotograma y al centroide de la muñeca, alcanzan tasas de reconocimiento correctas superiores al 94% en condiciones de iluminación controlada. El módulo de esta capa aplica adicionalmente un filtro de suavizado EWMA con factor de decaimiento $\alpha = 0.85$ sobre la secuencia temporal de keypoints, produciendo trayectorias gestuales suavizadas que reducen la sensibilidad del sistema a los micromovimientos involuntarios.

2.2.2 Capa 2: Procesamiento por Agentes Inteligentes

La segunda capa constituye el núcleo computacional del sistema. Alojada en la infraestructura de servidor, esta capa recibe las secuencias de keypoints transmitidas desde la capa de percepción a través de canales WebSocket de baja latencia, y las procesa mediante el sistema multi-agente para generar las representaciones semánticas intermedias requeridas por el LLM.

Dentro de esta capa operan los agentes previamente definidos: el Agente Codificador recibe la secuencia de ventanas temporales de keypoints (cada ventana comprende $T=30$ fotogramas, equivalentes a 1 segundo de video) y las proyecta a un espacio de embedding de dimensión $D=512$ mediante una red de codificación temporal basada en una arquitectura Transformer encoder-only. Este embedding captura tanto la configuración espacial instantánea de la mano como la dinámica temporal del movimiento, representando la señal como un punto en un espacio semántico de alta dimensionalidad.



El Agente Traductor toma el embedding generado y lo utiliza como condicionamiento para la generación autoregressiva de texto mediante el LLM. Para optimizar la latencia de inferencia, el agente implementa la técnica de KV-Cache (Key-Value Cache), que almacena los estados de atención de los tokens ya procesados, evitando su recómputo en cada paso de generación. Esta optimización reduce el tiempo de generación de una oración promedio de 10 tokens de 280ms a aproximadamente 45ms en hardware de servidor de gama media, cumpliendo los requisitos de interactividad del sistema.

La comunicación entre el Agente Codificador y el Agente Traductor se realiza a través de una cola de mensajes implementada con el protocolo AMQP (Advanced Message Queuing Protocol), que garantiza la entrega ordenada y confiable de los embeddings generados. Este diseño de cola desacopla temporalmente los dos agentes, permitiendo que el Agente Codificador opere al ritmo de la tasa de video (30 Hz) mientras el Agente Traductor gestiona su propia tasa de generación de texto sin bloquear el pipeline visual.

2.2.3 Capa 3: Generación de Lenguaje Natural Contextualizado

La tercera capa se enfoca exclusivamente en el proceso de generación de texto en español a partir de los embeddings producidos por la capa anterior. Su componente central es el LLM fine-tuneado sobre corpus de LSC, que actúa como el decodificador semántico final del sistema.

El proceso de generación opera en dos modos: (a) Modo de Traducción Directa: la seña detectada en la ventana temporal actual es traducida directamente al token o secuencia de tokens correspondiente en español, sin consideración del contexto anterior. Este modo es óptimo para señas aisladas o en contextos donde la coherencia discursiva no es crítica; (b) Modo de Generación Contextual: el LLM recibe como entrada tanto el embedding de la seña actual como los últimos K



tokens generados (historial de contexto), produciendo una traducción que respeta la coherencia gramatical y semántica del discurso en curso. Este modo es el prioritario para el sistema propuesto, ya que es el que efectivamente supera las limitaciones de las traducciones literales señaladas en el planteamiento del problema.




Ilustración 5Tuneo Del Fine Tuning Para Conversion Del Lenguaje Normal a Natural

Para el manejo de las especificidades gramaticales de la LSC, el Agente Traductor incorpora un módulo de post-procesamiento lingüístico que aplica reglas de transformación SOV→SVO sobre el texto generado, ajustando el orden de los constituyentes para producir oraciones naturales en español. Este módulo opera como una gramática de transformación de segundo orden que actúa sobre los árboles de análisis sintáctico (parse trees) del texto generado, sin modificar el proceso de generación del LLM y preservando así su generalización

2.2.4 Capa 4: Presentación e Interfaz de Usuario

La capa de presentación es la interfaz a través de la cual el usuario interactúa con el sistema. Diseñada bajo los principios de accesibilidad universal y experiencia de usuario centrada en la



persona, esta capa renderiza en tiempo real el texto traducido generado por el LLM, junto con una visualización del esqueleto de puntos clave superpuesto sobre el video de la cámara del usuario.

Desde el punto de vista tecnológico, la capa de presentación se implementa como una Single Page Application (SPA) desarrollada con un framework JavaScript moderno (React o Vue.js), que se comunica con la capa de agentes inteligentes a través del canal WebSocket establecido. La arquitectura de la SPA sigue el patrón Model-View-ViewModel (MVVM), en el que el ViewModel actúa como puente reactivo entre los datos del canal WebSocket y la representación visual en el navegador, garantizando actualizaciones de la interfaz con latencias inferiores a 16ms (tasa de refresco de 60 Hz).

En línea con las recomendaciones de la Universidad de Boyacá [5] sobre diseño de interfaces inclusivas, la interfaz contempla: tamaño de fuente ajustable, alto contraste configurable, retroalimentación visual y textual simultánea, y compatibilidad con lectores de pantalla. Adicionalmente, se prevé el soporte de múltiples idiomas de salida (español colombiano estándar y variantes regionales), lo que amplía el alcance del sistema más allá del contexto inmediato de Cúcuta y Norte de Santander.

2.3 Diagrama de Flujo de Datos del Sistema

El flujo de datos del sistema puede describirse formalmente como una cadena de transformaciones funcionales encadenadas. Sea $V(t)$ la secuencia de fotogramas de video en el instante t , $K(t)$ el vector de keypoints extraído de $V(t)$, $E(t)$ el embedding generado por el Agente Codificador a partir de $K(t)$, y $T(t)$ el texto en español generado por el LLM condicionado a $E(t)$ y al historial $H(t-1)$. La cadena de transformación es entonces: $V(t) \rightarrow K(t) \rightarrow E(t) \rightarrow T(t)$, donde cada flecha representa la operación realizada por la capa correspondiente de la arquitectura.



Esta representación formal permite identificar con claridad los puntos de optimización del sistema: la transformación $V(t) \rightarrow K(t)$ está dominada por el tiempo de inferencia de MediaPipe ($\approx 8-12$ ms); la transformación $K(t) \rightarrow E(t)$ por el tiempo de forward pass del Transformer encoder ($\approx 15-25$ ms); y la transformación $E(t) \rightarrow T(t)$ por el tiempo de generación autoregresiva del LLM ($\approx 30-60$ ms con KV-Cache). La latencia total del sistema, en condiciones óptimas, se proyecta por tanto en el rango de 53-97 ms, valor compatible con los estándares de comunicación en tiempo real y muy inferior al umbral de percepción de retardo por el usuario humano ($\approx 150-200$ ms).

2.4 Integración con Plataformas Digitales

Un requisito funcional central del sistema es su capacidad de integración con plataformas digitales existentes, en particular plataformas de videoconferencia y sistemas de gestión de aprendizaje (LMS) utilizados en instituciones educativas de Norte de Santander como las identificadas por Jiménez & Serrano [8] en el SENA Regional. Para satisfacer este requisito, la arquitectura propone la exposición de una API REST documentada bajo el estándar OpenAPI 3.0, que permite a plataformas externas invocar las capacidades de traducción del sistema de manera programática.




Ilustración 6 Contemplación De Apis Para La Conexión Con Páginas de Videoconferencias



La API contempla los siguientes endpoints funcionales: (a) /api/v1/translate/frame: recibe un fotograma codificado en base64 y retorna el vector de keypoints extraído; (b) /api/v1/translate/sequence: recibe una secuencia de vectores de keypoints y retorna el texto traducido; y (c) /api/v1/translate/stream: establece un canal WebSocket bidireccional para la traducción continua en tiempo real. Este diseño de API sigue los principios de REST constraints (statelessness, uniform interface, layered system) y garantiza la interoperabilidad del sistema con cualquier plataforma digital que implemente el protocolo HTTP/HTTPS y WebSockets estándar.



Objetivo Específico 3

Especificar los requerimientos técnicos, algoritmos de aprendizaje profundo y estrategias de entrenamiento necesarios para la puesta en marcha del modelo de reconocimiento de señas.

3.1 Requerimientos Técnicos del Sistema

3.1.1 Requerimientos de Hardware

Para garantizar la viabilidad operativa del sistema en el entorno de desarrollo y en el entorno de despliegue proyectado, se especifican los siguientes requerimientos mínimos de hardware. En el lado del cliente (navegación del usuario):

- Procesador con soporte de instrucciones AVX2 o superior para la ejecución eficiente de modelos WebAssembly.




Ilustración 7 Visualización Del Procesador Con Soporte AVX2



- Memoria RAM mínima de 4 GB disponibles para el proceso del navegador.
- Tarjeta gráfica integrada o discreta con soporte de WebGL 2.0.



Ilustración 8 Visualización Del Soporte Necesario De la Tarjeta Gráfica WebG

- Cámara web con resolución mínima de 720p (1280×720 píxeles) y tasa de fotogramas de 30 FPS.
- Conectividad a Internet con ancho de banda mínimo de 1 Mbps para la comunicación con el servidor de agentes.

En el lado del servidor (infraestructura de agentes y LLM): procesador de 8 núcleos o superior (arquitectura x86-64) con soporte de instrucciones AVX-512 para la aceleración de operaciones matriciales; memoria RAM mínima de 32 GB para el almacenamiento en memoria del modelo LLM y los buffers de procesamiento; GPU NVIDIA con capacidad de cómputo (Compute Capability) ≥ 7.0 y mínimo 8 GB de VRAM para la aceleración de la inferencia del LLM; almacenamiento SSD de alta velocidad (≥ 500 MB/s lectura secuencial) para la carga rápida



de los pesos del modelo; y conectividad de red con latencia máxima de 50ms hacia los clientes del sistema, consistente con los análisis de rendimiento en sensores inteligentes de Jin et al. [3]

3.1.2 Requerimientos de Software

El stack tecnológico del sistema se estructura en dos entornos: cliente y servidor. En el entorno cliente: navegador web moderno con soporte de WebAssembly y WebGL 2.0 (Google Chrome ≥ 90 , Mozilla Firefox ≥ 88 , Microsoft Edge ≥ 90); biblioteca MediaPipe Tasks Vision v0.10.x para la extracción de keypoints en el navegador; framework JavaScript de frontend (React ≥ 18 o Vue.js ≥ 3) para la construcción de la SPA; y cliente WebSocket nativo del navegador para la comunicación en tiempo real con el servidor.

En el entorno servidor: Python ≥ 3.10 como lenguaje base del entorno de agentes; PyTorch ≥ 2.0 como framework de aprendizaje profundo para el entrenamiento y la inferencia de los modelos; HuggingFace Transformers ≥ 4.35 para la gestión del LLM y sus utilidades de tokenización y generación; FastAPI ≥ 0.100 para la exposición de la API REST y los endpoints WebSocket; y Redis ≥ 7.0 como broker de colas de mensajes para la comunicación asíncrona entre agentes. Adicionalmente, se contempla el uso de NVIDIA TensorRT para la optimización de la inferencia del LLM en GPU, herramienta que puede reducir la latencia de generación hasta en un 40% respecto a la inferencia PyTorch nativa, según benchmarks publicados por NVIDIA (2024).



Python 3

Ilustración 9 Entorno Del Trabajo Del Servidor

3.2 Algoritmos de Aprendizaje Profundo

3.2.1 Arquitectura del Codificador Temporal: Transformer Encoder

El Agente Codificador emplea una arquitectura Transformer encoder-only para la codificación de las secuencias temporales de keypoints. Formalmente, dado un tensor de entrada $X \in \mathbb{R}^{(T \times D_{in})}$, donde T es el número de fotogramas en la ventana temporal ($T=30$) y D_{in} es la dimensionalidad del vector de keypoints ($225 \text{ puntos} \times 3 \text{ coordenadas} = 675$), el Transformer encoder aplica las siguientes operaciones secuenciales:




Ilustración 10 Algoritmo De Aprendizaje Profundo

(1) Proyección de entrada: X es proyectado a un espacio de embedding de dimensión $D_{model} = 512$ mediante una capa lineal $W_{in} \in \mathbb{R}^{(D_{in} \times D_{model})}$; (2) Codificación



posicional: se añade al embedding una codificación posicional sinusoidal $P \in \mathbb{R}^{(T \times D_{\text{model}})}$ que preserva la información temporal de cada fotograma en la secuencia; (3) Bloques de Atención Multi-Cabeza: $N=6$ bloques secuenciales de atención multi-cabeza (con $H=8$ cabezas de atención y $d_k = D_{\text{model}}/H = 64$) procesan el embedding enriquecido, capturando dependencias temporales de largo alcance entre los fotogramas de la secuencia; y (4) Proyección de salida: el estado del token [CLS] al final de los N bloques es proyectado a la dimensión del espacio de embedding del LLM ($D_{\text{embed}} = 4096$ para modelos tipo LLaMA-7B) mediante una capa lineal de adaptación.

Esta arquitectura, validada por Yerimbetova et al. [1] en el contexto del reconocimiento de lengua de señas con MediaPipe, ha demostrado superioridad respecto a alternativas basadas en LSTM o GRU, tanto en métricas de precisión (accuracy y WER —Word Error Rate—) como en eficiencia computacional durante la inferencia, gracias a la naturaleza paralelizable del mecanismo de atención.

3.2.2 Modelo de Lenguaje: Selección y Configuración

Para el componente LLM del sistema, se propone el uso de LLaMA-3-8B-Instruct como modelo base, por las siguientes razones técnicas: (a) su tamaño de 8 billones de parámetros representa un equilibrio óptimo entre capacidad generativa y eficiencia de inferencia en hardware de servidor de gama media; (b) su entrenamiento en un corpus multilingüe que incluye texto en español garantiza competencias lingüísticas nativas en el idioma objetivo del sistema; (c) su arquitectura de Grouped Query Attention (GQA) reduce el consumo de VRAM durante la inferencia sin degradar significativamente la calidad de generación; y (d) su licencia Meta Llama 3 Community License permite su uso en proyectos de investigación académica sin costo.



Ilustración 11 Selección Del Modelo De Aplicación Base

El proceso de fine-tuning del modelo base sobre el corpus de LSC se realizará mediante la técnica QLoRA (Quantized Low-Rank Adaptation), que combina la cuantización del modelo a 4 bits (NF4) con la adición de adaptadores de bajo rango (rank=16, alpha=32) sobre las matrices de proyección Q, K, V y O del mecanismo de atención. Esta técnica reduce el número de parámetros entrenables de 8 billones a aproximadamente 21 millones, permitiendo el fine-tuning del modelo en una GPU de 8GB de VRAM, hardware disponible en los laboratorios de la Universidad de Pamplona. El entrenamiento se realizará durante 3 épocas sobre el corpus de LSC, con un learning rate de 2×10^{-4} y un scheduler de tipo cosine annealing con reinicio caliente.

3.3 Estrategias de Entrenamiento

3.3.1 Corpus de Entrenamiento y Gestión de Datos

La calidad del corpus de entrenamiento es el factor determinante en el rendimiento del sistema de reconocimiento de señas. Para el presente proyecto, se propone la construcción de un corpus mixto que combina dos fuentes de datos: (A) Corpus Públicos Existentes: el dataset AUTSL (Academia Turca de Lengua de Señas) con 226 clases de señas y 38,336 videos, utilizado por Yerimbetova et al. [1] como punto de partida para el preentrenamiento del codificador temporal;



y el dataset INCLUDE (Indian Sign Language dataset) con 263 clases y 4,287 clips de video, empleado para aumentar la variabilidad de condiciones de captura en el preentrenamiento.

(B) Corpus LSC Regional: un conjunto de datos específico de la Lengua de Señas Colombiana, recopilado en colaboración con intérpretes y usuarios de la comunidad sorda de Norte de Santander, en concordancia con el enfoque comunitario de los trabajos de Vargas & Peñuela [9] y Jiménez & Serrano [8] en la región. Este corpus abarcará inicialmente 200 señas de alta frecuencia en contextos educativos y de servicios públicos, con un mínimo de 50 repeticiones por seña ejecutadas por 10 sujetos diferentes, garantizando diversidad en anatomía de la mano, velocidad de ejecución y variaciones dialectales.

El procesamiento del corpus incluye las siguientes etapas de ingeniería de datos: extracción de keypoints mediante MediaPipe para la conversión de los videos crudos a secuencias de vectores de keypoints normalizados; segmentación automática de señas mediante un detector de inicio/fin de movimiento basado en la varianza de los keypoints a lo largo del tiempo; aumento de datos (data augmentation) mediante transformaciones geométricas (rotación $\pm 15^\circ$, escalado 0.8-1.2, espejado horizontal), perturbaciones temporales (velocización 0.8-1.2x) y adición de ruido gaussiano ($\sigma=0.01$) sobre los vectores de keypoints; y división del corpus en conjuntos de entrenamiento (70%), validación (15%) y prueba (15%), estratificada por seña y sujeto.

3.3.2 Función de Pérdida y Métricas de Evaluación

El entrenamiento del sistema se optimiza mediante dos funciones de pérdida complementarias. Para el Codificador Temporal, se emplea una pérdida de Contrastive Learning tipo NT-Xent (Normalized Temperature-scaled Cross Entropy Loss), que maximiza la similitud entre los embeddings de diferentes repeticiones de la misma seña mientras minimiza la similitud



entre embeddings de señas distintas. Esta función de pérdida, ampliamente utilizada en aprendizaje auto-supervisado, permite al Codificador aprender representaciones discriminativas sin requerir etiquetas exhaustivas para cada sample del corpus.

Para el LLM en el proceso de fine-tuning, se emplea la función estándar de Entropía Cruzada Categórica (Cross-Entropy Loss) sobre los tokens de la secuencia de texto objetivo, con enmascaramiento del segmento de prompt para que la pérdida solo se compute sobre los tokens de la traducción generada. Esta formulación es la estándar para el ajuste fino de modelos de lenguaje en tareas de traducción supervisada y garantiza que el modelo aprenda a generar texto fluido y gramaticalmente correcto en español.

Para la evaluación del sistema, se proponen las siguientes métricas cuantitativas:

(A) Top-1 Accuracy: porcentaje de señas correctamente clasificadas en el conjunto de prueba, empleada para evaluar el rendimiento del Codificador Temporal en tareas de clasificación de señas aisladas.




Ilustración 12 Métrica De Evaluacion Accuracy Para Clasificacion De Cantidad de Error



(B) Word Error Rate (WER): métrica estándar en reconocimiento de habla y lengua de señas que mide el porcentaje de palabras incorrectas en las transcripciones generadas respecto a las referencias.

$$\text{Word Error Rate} = \frac{\text{Insertions} + \text{Deletions} + \text{Substitutions}}{\text{Number of words in the ground truth}}$$

$$\text{WER} = \frac{0+0+1}{4} = \frac{1}{4}$$

Ilustración 13 Métrica Para El Cálculo Del Estándar De Error Del Sistema

(C) BLEU Score: métrica de evaluación de calidad de traducción automática que compara los n-gramas de la traducción generada con los de la referencia humana.

$$\begin{aligned} \text{Geometric Average Precision (N)} &= \exp\left(\sum_{n=1}^N w_n \log p_n\right) \\ &= \prod_{n=1}^N p_n^{w_n} \\ &= (p_1)^{\frac{1}{4}} \cdot (p_2)^{\frac{1}{4}} \cdot (p_3)^{\frac{1}{4}} \cdot (p_4)^{\frac{1}{4}} \end{aligned}$$

Ilustración 14 Métrica Para La Calidad De Traducción Humana

(D) Latencia de Inferencia (ms): tiempo total desde la captura del primer fotograma de la seña hasta la generación del último token de la traducción, medida en el percentil 95 de las solicitudes procesadas.



3.3.3 Estrategia de Transferencia de Conocimiento

Dado que el corpus de LSC regional propuesto ($200 \text{ clases} \times 50 \text{ repeticiones} \times 10 \text{ sujetos} = 100,000 \text{ muestras}$) puede resultar insuficiente para entrenar un Codificador Temporal desde cero con alta generalización, se propone una estrategia de Transfer Learning en dos fases. En la Fase 1 (Preentrenamiento General), el Codificador Temporal es entrenado en el corpus público combinado (AUTSL + INCLUDE) durante 50 épocas, aprendiendo representaciones generales de keypoints de manos que son independientes del lenguaje de señas específico. En la Fase 2 (Fine-Tuning LSC), el Codificador preentrenado es ajustado sobre el corpus LSC regional durante 20 épocas adicionales, con una tasa de aprendizaje reducida ($10\times$) en las capas inferiores para preservar los patrones generales aprendidos y una tasa de aprendizaje estándar en las capas superiores para adaptar las representaciones a las particularidades de la LSC.

Esta estrategia de dos fases ha demostrado consistentemente superar el entrenamiento desde cero en escenarios de recursos limitados, tal como lo reporta Yerimbetova et al. [1], quien obtuvo mejoras de hasta 12 puntos porcentuales en Top-1 Accuracy al aplicar transfer learning desde modelos preentrenados en lenguas de señas con mayor cobertura de datos hacia lenguas de señas con menor representación en corpus públicos. En el contexto del presente proyecto, esta estrategia es especialmente relevante dado que la LSC no cuenta actualmente con datasets públicos de gran escala comparables a los disponibles para la ASL o la lengua de señas de Kazajistán estudiada por Yerimbetova et al.

3.4 Plan de Mitigación de Riesgos Técnicos

La especificación técnica del sistema identifica los siguientes riesgos de implementación y sus correspondientes estrategias de mitigación: (a) Riesgo de corpus insuficiente: mitigado mediante la estrategia de transfer learning descrita, el aumento de datos y la incorporación



progresiva de nuevas grabaciones de la comunidad LSC regional, en línea con el enfoque de investigación-acción participativa propuesto por la UNAD [6]; (b) Riesgo de latencia excesiva: mitigado mediante la optimización del modelo con TensorRT, el uso de KV-Cache en el LLM y el diseño asíncrono del pipeline de procesamiento; (c) Riesgo de variabilidad de iluminación y oclusión: mitigado mediante el filtrado EWMA, el aumento de datos con variaciones de iluminación simulada y la inclusión en el corpus de grabaciones bajo diferentes condiciones ambientales; y (d) Riesgo de generalización insuficiente del LLM hacia la LSC: mitigado mediante la técnica QLoRA de fine-tuning eficiente y la evaluación sistemática sobre el conjunto de prueba estratificado, con retroalimentación de intérpretes nativos de LSC para la validación cualitativa de las traducciones generadas.



Conclusiones

El desarrollo de los tres primeros objetivos específicos del proyecto ha permitido establecer una base técnica sólida, coherente y fundamentada para el sistema inteligente de interpretación de lengua de señas. En el primer objetivo, se identificaron y articularon los tres pilares tecnológicos del sistema: la visión computacional basada en MediaPipe, los modelos de lenguaje de gran escala y la filosofía de agentes i5.0, demostrando su complementariedad funcional y su alineación con los principios de la Industria 5.0 en términos de centralidad humana, sostenibilidad y resiliencia.

En el segundo objetivo, se diseñó una arquitectura lógica y funcional de cuatro capas (Percepción, Agentes, Generación de Lenguaje y Presentación) que satisface los requisitos de baja latencia, modularidad y escalabilidad del sistema. El análisis formal de la cadena de transformaciones de datos permitió proyectar latencias totales de 53-97 ms, compatibles con los estándares de comunicación en tiempo real. La exposición de una API REST y un canal WebSocket garantiza la integrabilidad del sistema con plataformas digitales educativas y de servicios públicos en la región.

En el tercer objetivo, se especificaron con rigor técnico los algoritmos de aprendizaje profundo (Transformer encoder + LLM LLaMA-3-8B con QLoRA), las estrategias de gestión de corpus (mixto público + LSC regional con data augmentation) y las métricas de evaluación (Top-1 Accuracy, WER, BLEU, latencia) que permitirán valorar objetivamente el rendimiento del sistema. La estrategia de transfer learning en dos fases es especialmente relevante para superar la limitación de corpus LSC disponibles públicamente.



En conjunto, estos tres objetivos configuran el plan de ingeniería básica del sistema, estableciendo los cimientos sobre los cuales los objetivos posteriores podrán desarrollar la integración con plataformas web, la validación empírica y la proyección del caso de estudio regional en Norte de Santander. El presente trabajo es coherente con los planteamientos de Pérez León [7] sobre las necesidades de la comunidad sorda en Cúcuta y con las recomendaciones del SENA Regional [8] sobre herramientas multimedia inclusivas, representando un aporte concreto de la ingeniería de sistemas al cierre de la brecha comunicativa de la comunidad sorda en la región.



Referencias

- [1] Yerimbetova, A., Berzhanova, U., et al. (2026). Sign Language Recognition based on Deep Learning via MediaPipe for people with speech and hearing impairments. *Procedia Computer Science*, 275, 359–368.
- [2] Alsaleh, A. (2026). The influence of artificial intelligence on individuals with disabilities. *Acta Psychologica*, 262, 106010.
- [3] Jin, H., Wang, W., et al. (2026). Flexible wearable sensors for sports training: recent advances and future perspectives. *Materials & Design*, 265, 115994.
- [4] Revista Facultad de Ingeniería. (2025). Tendencias y desafíos de la ingeniería en el contexto colombiano. *Revista Facultad de Ingeniería UdeA*, 34(70).
- [5] Universidad de Boyacá. (2025). Desarrollo de herramientas digitales para la inclusión social. Repositorio Institucional UniBoyacá.
- [6] Universidad Nacional Abierta y a Distancia – UNAD. (2025). Aplicaciones de la IA en la comunicación inclusiva. Repositorio Digital UNAD.
- [7] Pérez León, E. E. (2021). Discapacidad auditiva y pedagogías emergentes: desafíos y retos de un modelo de educación mediado por las tecnologías digitales. Instituto Técnico Guaimaral, Cúcuta.



- [8] Jiménez Rivera, L. F., & Serrano Gelvez, H. A. (2022). Estrategia pedagógica multimedia para la integración de las TIC en estudiantes con problemas auditivos del SENA Regional Norte de Santander. Universidad Simón Bolívar, Cúcuta.
- [9] Vargas Salcedo, D. P., & Peñuela Bermúdez, D. P. (2022). Estrategias didácticas para el desarrollo de la competencia matemática en estudiantes con déficit auditivo del Colegio Técnico Guaimaral. Universidad Francisco de Paula Santander (UFPS).
- [10] ResearchGate, "Figura 1: Pipeline de visualización 3D." [Online]. Available: https://www.researchgate.net/figure/Figura-1-Pipeline-de-visualizacion-3D_fig1_322083041
- [11] ResearchGate, "Accuracy Comparison of the Methods Across Different Software Systems." [Online]. Available: https://www.researchgate.net/figure/Accuracy-Comparison-of-the-Methods-Across-Different-Software-Systems_fig13_341148842
- [12] Deepgram, "Measuring Quality: Word Error Rate (WER) Explained." [Online]. Available: <https://deepgram.com/learn/measuring-quality-word-error-rate-explained>
- [13] Ketanhdoshi, "Bleu Score & WER." [Online]. Available: <https://ketanhdoshi.github.io/Bleu-Score-WER/>
- [14] Bizfly, "WebGL là gì? Tổng quan về WebGL trong lập trình web." [Online]. Available: <https://bizfly.vn/techblog/webgl-la-gi.html>



[15] Docsity, "Guía Python 3.0: Dispensa." [Online]. Available:
<https://www.docsity.com/it/guida-python-3-0-dispensa/6999828/>

[16] Dyte, "Video conferencing APIs: Everything you need to know." [Online]. Available:
<https://dyte.io/blog/video-conferencing-apis/>

[17] S. Himasai, "Pose estimation using Mediapipe." [Online]. Available:
<https://medium.com/@himasaiswaroop/pose-estimation-using-mediapipe-4d8c81f56a4f>

[18] My Great Learning, "What is fine-tuning?" [Online]. Available:
<https://www.mygreatlearning.com/blog/what-is-fine-tuning/>

[19] Profesional Review, "¿Qué es AVX?," Dec. 7, 2019. [Online]. Available:
<https://www.profesionalreview.com/2019/12/07/que-es-avx/>

[20] Solulab, "Fine-tuning a model for a specific task." [Online]. Available:
<https://www.solulab.com/fine-tuning-a-model-for-a-specific-task/>

[21] TatvaSoft, "JavaScript vs TypeScript: Which one to choose?" [Online]. Available:
<https://www.tatvasoft.com/blog/javascript-vs-typescript/>

[22] Yerimbetova, A., Berzhanova, U., et al. (2026). Sign Language Recognition based on Deep Learning via MediaPipe for people with speech and hearing impairments. *Procedia Computer Science*, 275, 359-368. ScienceDirect.

[23] Alsaleh, A. (2026). The influence of artificial intelligence on individuals with disabilities. *Acta Psychologica*, 262, 106010. ScienceDirect.



- [24] Jin, H., Wang, W., et al. (2026). Flexible wearable sensors for sports training: recent advances and future perspectives. *Materials & Design*, 265, 115994. ScienceDirect.
- [25] Revista Facultad de Ingeniería (2025). Tendencias y desafíos de la ingeniería en el contexto colombiano. *Scielo Colombia*. Vol. 34, No. 70.
- [26] Universidad de Boyacá (2025). Desarrollo de herramientas digitales para la inclusión social. Repositorio Institucional UniBoyacá.
- [27] Universidad Nacional Abierta y a Distancia - UNAD (2025). Aplicaciones de la IA en la comunicación inclusiva. Repositorio Digital UNAD.
- [28] Pérez León, E. E. (2021). Discapacidad auditiva y pedagogías emergentes: Desafíos y retos de un modelo de educación mediado por las tecnologías digitales. Instituto Técnico Guaimaral, Cúcuta.
- [29] Jiménez Rivera, L. F. & Serrano Gelvez, H. A. (2022). Estrategia pedagógica multimedia para la integración de las TIC en estudiantes con problemas auditivos del SENA Regional Norte de Santander. Universidad Simón Bolívar, Cúcuta.
- [30] Vargas Salcedo, D. P. & Peñuela Bermúdez, D. P. (2022). Estrategias didácticas para el desarrollo de la competencia matemática en estudiantes con déficit auditivo del Colegio Técnico Guaimaral. Universidad Francisco de Paula Santander (UFPS).